


판다스 (pandas) : 데이터 전처리

한국폴리텍대학 성남캠퍼스 인공지능소프트웨어과
이혜정 교수

1

데이터 분석 절차



■ 문제 정의

- 무엇을 알고 싶은가?
- 분석의 목적과 질문을 명확하게 정하는 단계

■ 데이터 수집

- 분석 목적에 맞는 데이터를 확보

■ 데이터 전처리

- 데이터를 분석할 수 있는 상태로 정리
- 수집한 데이터에는 분석을 방해하는 여러 문제가 있을 수 있음
 - 결측치, 중복 데이터, 이상치, 데이터 타입 등

■ 데이터 탐색 및 분석

- 데이터의 기본적인 특징을 확인하고 변수 간 패턴 찾기
- 데이터 구조 확인, 통계적 분석, 그룹별 비교, 분포 확인 등

■ 데이터 시각화

- 분석 결과를 그래프로 확인


■ 결과 해석 및 활용

- 분석 결과를 단순히 숫자로 제시하는 것이 아니라 의미를 해석하여 의사결정에 활용

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이혜정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

2

데이터 처리



※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

3

3

데이터프레임의 데이터 구조 및 구성 확인하기

- `dataframe.head(num_row=5)` : 앞 부분 출력
- `dataframe.tail(num_row=5)` : 뒷 부분 출력
- `dataframe.shape` : 행, 열의 크기
- `dataframe.info()` : 데이터 갯수, null값(결측치, NaN) 등 확인
- `python len(dataframe)` : 데이터 갯수
- `dataframe.describe()` : 기술 통계값
 - 데이터형이 float나 int인 열에만 적용
 - 각 열의 개수(count), 평균(mean), 표준편차(std), 최솟값(min), 최댓값(max) 등의 통계치 확인 가능

```
sample_df = pd.read_csv('./data/sample_data.csv')
sample_df.head(3)
sample_df.tail(3)
sample_df.shape
sample_df.info()
len(sample_df)
```

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

4

4

데이터의 접근/추출

방식		방법	접근 기준	주요 특징
범위 지정	직접	df[col_name]	열 이름	열 추출
		df[slicing]	행 번호	행 추출
		df[row][col]	행/열	행은 slicing, 열은 열 이름으로
	인덱스 이용	df.loc[row,col]	행/열 레이블	이름으로 접근, 슬라이싱 끝점 포함
		df.iloc[row,col]	행/열 번호	숫자로 접근, 슬라이싱 끝점 제외
조건 지정		[]에 condition 사용	불리언 조건	조건 필터링 시 사용

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

5

5

그룹별로 요약하여 데이터 확인

	<code>value_counts()</code>	<code>groupby()</code>	<code>pivot_table()</code>
목적	범주별 빈도 → 값별 개수 세기	그룹별 집계·분석(통계)	두 개 이상의 그룹을 행×열 형태로 집계
설명	특정 컬럼에 어떤 값이 몇 번 나타나는지 세는 함수	데이터를 특정 기준으로 나누는 다음 각 그룹에 다양한 통계 함수를 적용	두 개 이상의 기준으로 데이터를 집계하여 표로 표현
그룹 기준	값 자체	하나 이상의 컬럼	index + columns
대표 집계	개수, 비율	합계, 평균, 최대/최소 등	합계, 평균, 개수 등
결과 형태	주로 Series	Series/DataFrame	DataFrame

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

6

6

범주별 빈도 : value_counts()

■ 특정 컬럼에 어떤 값이 몇 번 나타나는지 세는 함수

- 어떤 값이 몇 개인가?

- `normalize=False` : `True` 이면 개수 대신 **비율**로 반환
- `sort=True` : 빈도수를 기준으로 **정렬 여부** 지정
- `ascending=False` : `True` 이면 빈도수가 작은 값부터 오름차순 정렬
- `dropna=True` : `True` 이면 `NaN` 을 제외, `False` 이면 결측값도 집계

```
df['지역'].value_counts(  
    normalize=True,  
    ascending=False,  
    dropna=False  
)
```

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

7

7

그룹별 집계·분석 : groupby()

■ 데이터를 특정 기준으로 나눈 다음 각 그룹에 다양한 통계 함수를 적용

- 그룹마다 값이 어떻게 다른가를 확인
- 무엇을 기준으로 그룹화할 것인가?

- `by` : 데이터를 **그룹화할 기준 컬럼** 지정
 - 여러 컬럼을 리스트로 지정 가능: `by=['지역', '상품']`
- `as_index=True` : 그룹 기준 컬럼을 **결과의 인덱스로 사용할지** 지정
 - `False` 이면 그룹 기준이 일반 컬럼으로 유지됨
- `sort=True` : 그룹 기준값의 **정렬 여부** 지정
- `dropna=True` : 그룹 기준의 `NaN` 을 **제외할지** 지정

```
df.groupby(  
    by='지역',  
    as_index=False  
)['매출'].mean()
```

■ 그룹화한 후 적용하는 주요 집계 함수

- `sum()` : 합계
- `mean()` : 평균
- `count()` : 데이터 개수
- `max()` / `min()` : 최댓값 / 최솟값
- `agg()` : 여러 집계 함수를 동시에 적용

```
df.groupby('지역')['매출'].agg(  
    ['count', 'sum', 'mean']  
)
```

※ 본 자료는 2026년 2학기 『AI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

8

8

두 개 이상의 그룹을 표로 집계 : pivot_table()

■ 두 개 이상의 기준으로 데이터를 집계하여 표로 표현

- 두 개 이상의 기준으로 데이터를 표로 비교
- 무엇(values)을 행(index)과 열(columns)로 나누어 어떻게(aggfunc) 계산할 것인가?


- **values** : 집계할 값을 가진 컬럼 지정
- **index** : 피벗 테이블의 행 방향 그룹 기준 지정
- **columns** : 피벗 테이블의 열 방향 그룹 기준 지정
- **aggfunc='mean'** : 데이터를 어떤 방식으로 집계할지 지정
 - 'sum', 'mean', 'count', 'max', 'min' 등
- **fill_value** : 집계 결과의 결측값을 대체할 값 지정
 - 예: fill_value=0
- **margins=False** : True 이면 행과 열에 전체 집계 결과(All) 추가

```
df.pivot_table(
    values='매출',
    index='지역',
    columns='상품',
    aggfunc='sum',
    fill_value=0,
    margins=True
)
```

※ 본 자료는 2026년 2학기 「SI기반데이터분석 (이해정 교수)」 강의자료로 무단 배포 및 발해를 금합니다.

9

9



※ 본 자료는 2026년 2학기 「SI기반데이터분석 (이해정 교수)」 강의자료로 무단 배포 및 발해를 금합니다.

10

10

결측치 처리

■ 결측치

- 데이터에 값이 없는 것
- 데이터를 수집하는 과정에서 오류나 실수로 발생
- 데이터 분석의 정확도를 높이기 위해서는 결측치를 삭제하거나 0 또는 평균값으로 채우는 것이 좋음

■ 결측치 확인

- isna 함수
 - 결측치가 있으면 NaN 반환
- isnull 함수
 - 결측치가 있는지 확인 후 결측치가 있으면 불 인덱스 True를 반환 → 결측치인 NaN 값만 추출할 수 있음
 - sum 함수를 함께 사용하면 NaN 값이 총 몇 개인지 확인 가능
- notnull 함수
 - 결측치가 있는지 확인한 후 결측치가 없으면 불 인덱스 True 반환

```
# 컬럼별 결측치 확인
sample_df.isnull().sum()

# 행별 결측치 확인
sample_df.isnull().any(axis=1)

# 결측치가 있는 행 추출
null_df = sample_df[sample_df.isnull().any(axis=1)]
```

※ 본 자료는 2026년 2학기 『시 기반 데이터 분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

11

11

결측치 처리

■ 결측치 처리 방법

- 결측치 포함 행 삭제 : dataframe.dropna(subset=, inplace=)
 - subset = List (지정 된 범위에 null이 있을 경우 Row 삭제)
- 새로운 값으로 채우기 : dataframe.fillna(value, inplace=)
 - 특정 컬럼에 해당하는 값만 채우려는 경우 : DataFrame [name].fillna(...)

```
# 결측치가있는 행 삭제
sample_df.dropna(inplace=True)
sample_df.dropna(subset=['City'], inplace=True)
```

※ 본 자료는 2026년 2학기 『시 기반 데이터 분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

12

12

중복치 처리

■ 중복치

- 동일하거나 매우 유사한 데이터가 여러 번 저장된 것

■ 발생 원인

- 동일 데이터를 여러 번 입력
- 여러 데이터 파일을 합치는 과정에서 데이터가 중복
- 시스템 오류로 동일한 데이터가 반복 저장
- 웹 크롤링 과정에서 동일 페이지를 여러 번 수집

■ 처리해야 하는 이유

- 중복 데이터를 그대로 분석하면 분석 결과가 왜곡될 수 있음
- 예) 3명의 데이터에 중복치가 포함되어 4명의 데이터로 처리되는 경우
 - 데이터 개수가 실제보다 많아짐
 - 평균, 합계 등의 통계값 왜곡
 - 특정 데이터가 과도하게 반영
 - 머신러닝 모델 학습 결과에 편향 발생

※ 본 자료는 2026년 2학기 『SI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

13

13

중복치 처리

■ 중복치의 확인과 처리

- 중복값 확인 : `uplicated(keep=)`
 - `keep = True` (첫번째 미포함)
- 중복값 삭제 : `drop_duplicates(subset=, inplace=)`
 - `subset = List` (지정 된 범위에 null이 있을 경우 Row 삭제)

```
# 중복값인 행 확인
sample_df.duplicated()

# 중복값인 행 추출
du_df = sample_df[sample_df.duplicated()]
du_df = sample_df[sample_df.duplicated(keep=False)]

# 중복값인 행 삭제
sample_df.drop_duplicates(inplace=True)
```

※ 본 자료는 2026년 2학기 『SI기반데이터분석 (이해정 교수)』 강의자료로 무단 배포 및 발해를 금합니다.

14

14